



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

Отчёт по лабораторной работе №4 по дисциплине "Анализ алгоритмов"

Тема Параллельное умножение матриц

Студент Романов А.В.

Группа ИУ7-53Б

Оценка (баллы) _____

Преподаватели Волкова Л.Л., Строганов Ю.В.

Москва — 2020 г.

Оглавление

Введение	3
1 Аналитическая часть	5
1.1 Описание задачи	5
1.2 Вывод	5
2 Конструкторская часть	6
2.1 Схемы алгоритмов	6
2.2 Вывод	6
3 Технологическая часть	12
3.1 Требование к ПО	12
3.2 Средства реализации	12
3.3 Реализация алгоритмов	12
3.4 Тестовые данные	14
3.5 Вывод	14
4 Исследовательская часть	16
4.1 Технические характеристики	16
4.2 Время выполнения алгоритмов	16
4.3 Вывод	16
Заключение	18
Литература	18

Введение

Многопоточность — способность центрального процессора (CPU) или одного ядра в многоядерном процессоре одновременно выполнять несколько процессов или потоков, соответствующим образом поддерживаемых операционной системой.

Этот подход отличается от многопроцессорности, так как многопоточность процессов и потоков совместно использует ресурсы одного или нескольких ядер: вычислительных блоков, кэш-памяти ЦПУ или буфера перевода с преобразованием (TLB).

В тех случаях, когда многопроцессорные системы включают в себя несколько полных блоков обработки, многопоточность направлена на максимизацию использования ресурсов одного ядра, используя параллелизм на уровне потоков, а также на уровне инструкций.

Поскольку эти два метода являются взаимодополняющими, их иногда объединяют в системах с несколькими многопоточными ЦП и в ЦП с несколькими многопоточными ядрами.

Многопоточная парадигма стала более популярной с конца 1990-х годов, поскольку усилия по дальнейшему использованию параллелизма на уровне инструкций застопорились.

Смысл многопоточности — квазимногозадачность на уровне одного исполняемого процесса.

Значит, все потоки процесса помимо общего адресного пространства имеют и общие дескрипторы файлов. Выполняющийся процесс имеет как минимум один (главный) поток.

Многопоточность (как доктрину программирования) не следует путать ни с многозадачностью, ни с многопроцессорностью, несмотря на то, что операционные системы, реализующие многозадачность, как правило, реализуют и многопоточность.

Достоинства:

- облегчение программы посредством использования общего адресного пространства;
- меньшие затраты на создание потока в сравнении с процессами;
- повышение производительности процесса за счёт распараллеливания процессорных вычислений;
- если поток часто теряет кэш, другие потоки могут продолжать использовать неиспользованные вычислительные ресурсы.

Недостатки:

- несколько потоков могут вмешиваться друг в друга при совместном использовании аппаратных ресурсов [1];
- с программной точки зрения аппаратная поддержка многопоточности более трудоемка для программного обеспечения [2];

- проблема планирования потоков;
- специфика использования. Вручную настроенные программы на ассемблере, использующие расширения MMX или AltiVec и выполняющие предварительные выборки данных, не страдают от потерь кэша или неиспользуемых вычислительных ресурсов. Таким образом, такие программы не выигрывают от аппаратной многопоточности и действительно могут видеть ухудшенную производительность из-за конкуренции за общие ресурсы.

Однако несмотря на количество недостатков, перечисленных выше, многопоточная парадигма имеет большой потенциал на сегодняшний день и при должном написании кода позволяет значительно ускорить однопоточные алгоритмы.

Цель лабораторной работы

Целью данной лабораторной работы является изучение и реализация параллельных вычислений.

Задачи лабораторной работы

В рамках выполнения работы необходимо решить следующие задачи:

- изучить понятие параллельных вычислений;
- реализовать последовательный и 2 параллельных реализаций алгоритма перемножения матриц;
- сравнить временные характеристики реализованных алгоритмов экспериментально.

1 | Аналитическая часть

1.1 Описание задачи

Пусть даны две прямоугольные матрицы

$$A_{lm} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1m} \\ a_{21} & a_{22} & \dots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{l1} & a_{l2} & \dots & a_{lm} \end{pmatrix}, \quad B_{mn} = \begin{pmatrix} b_{11} & b_{12} & \dots & b_{1n} \\ b_{21} & b_{22} & \dots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m1} & b_{m2} & \dots & b_{mn} \end{pmatrix}, \quad (1.1)$$

тогда матрица C

$$C_{ln} = \begin{pmatrix} c_{11} & c_{12} & \dots & c_{1n} \\ c_{21} & c_{22} & \dots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{l1} & c_{l2} & \dots & c_{ln} \end{pmatrix}, \quad (1.2)$$

где

$$c_{ij} = \sum_{r=1}^m a_{ir} b_{rj} \quad (i = \overline{1, l}; j = \overline{1, n}) \quad (1.3)$$

будет называться произведением матриц A и B .

В данной лабораторной работе стоит задача распараллеливания алгоритма Винограда по 2 схемам. Так как каждый элемент матрицы C вычисляется независимо от других и матрицы A и B не изменяются, то для параллельного вычисления произведения, достаточно просто равным образом распределить элементы матрицы C между потоками.

1.2 Вывод

Обычный алгоритм перемножения матриц независимо вычисляет элементы матрицы-результата, что дает большое количество возможностей для реализации параллельного варианта алгоритма.

2 | Конструкторская часть

На рисунке 2.1 представлена схема обычного алгоритма перемножения матриц (без распараллеливания). На рисунках 2.2 и 2.3 представлены схемы первого и второго варианта распараллеливания алгоритма умножения матриц. На рисунке 2.4 показана схема функции, определяющая границы циклов для каждого из потоков.

2.1 Схемы алгоритмов

На рисунке 2.5 представлена схема с параллельным выполнением первого цикла (по строкам матрицы), а на рисунке 2.6 – с параллельным выполнением второго цикла (по столбам матрицы.)

2.2 Вывод

На основе теоретических данных, полученных из аналитического раздела, была построена схема стандартного алгоритма умножения матриц, а так же после разделения алгоритма на этапы были предложены 2 схемы параллельного выполнения данных этапов.

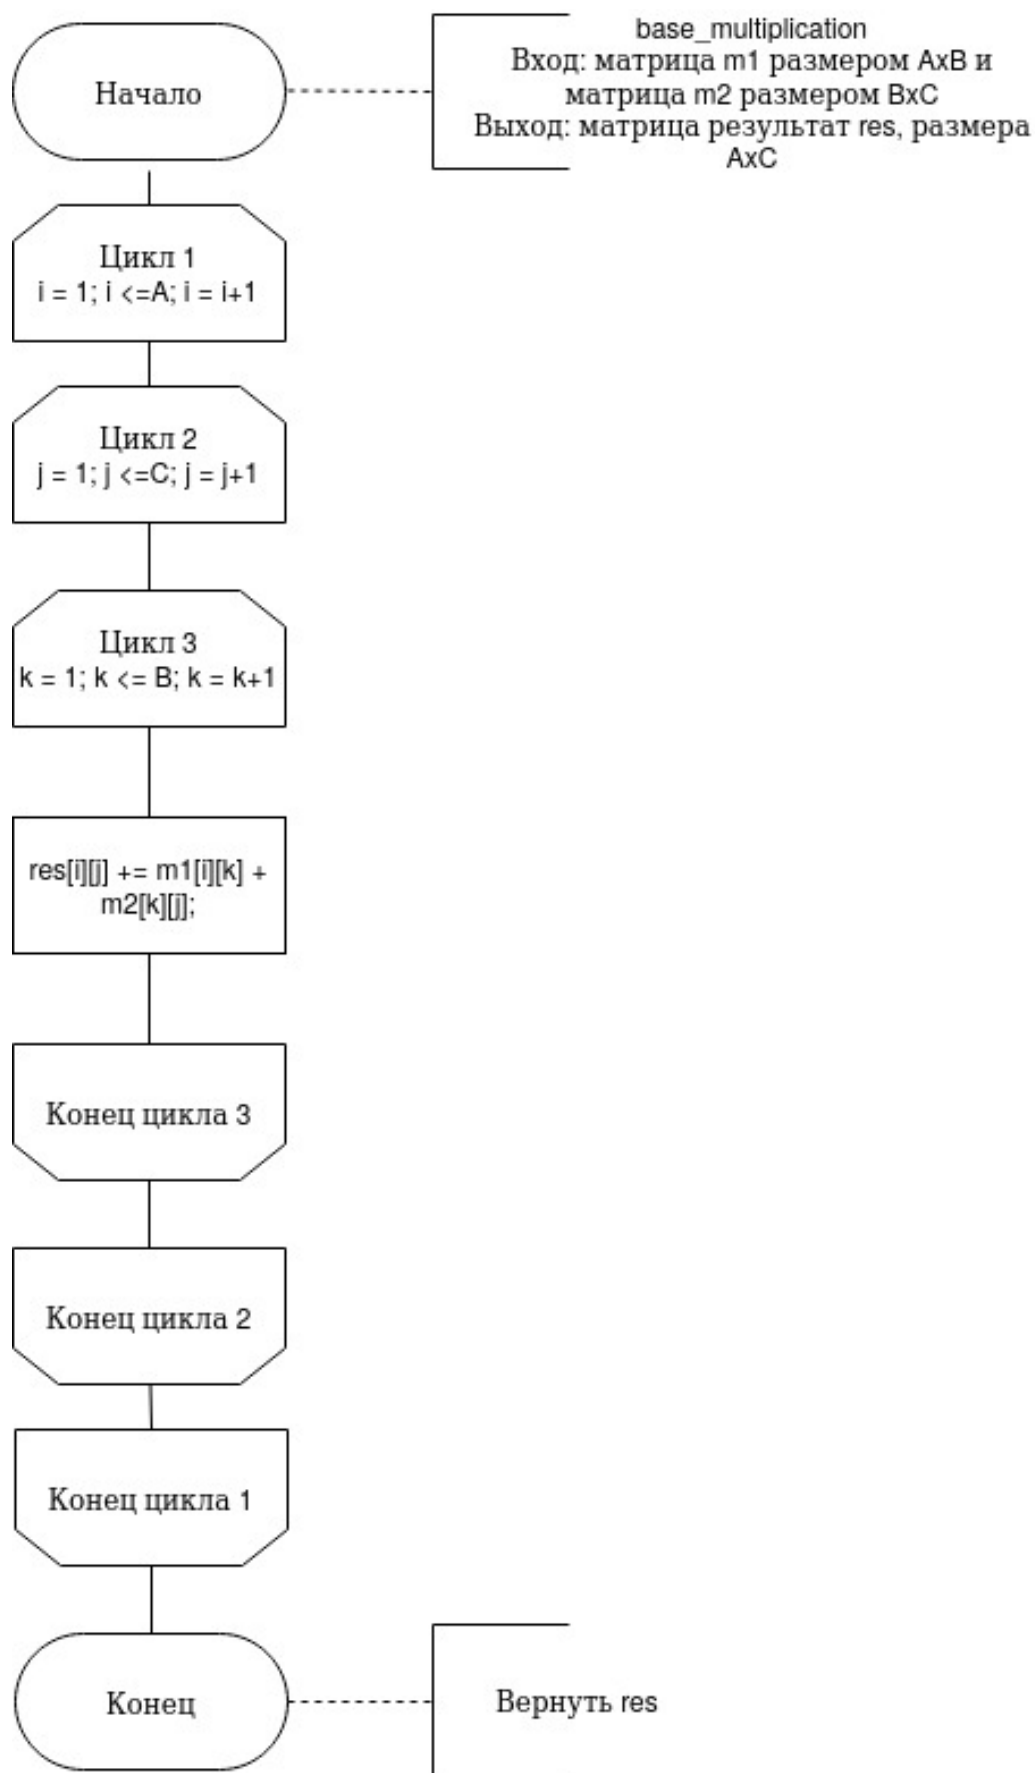


Рис. 2.1: Схема стандартного алгоритма умножения матриц.

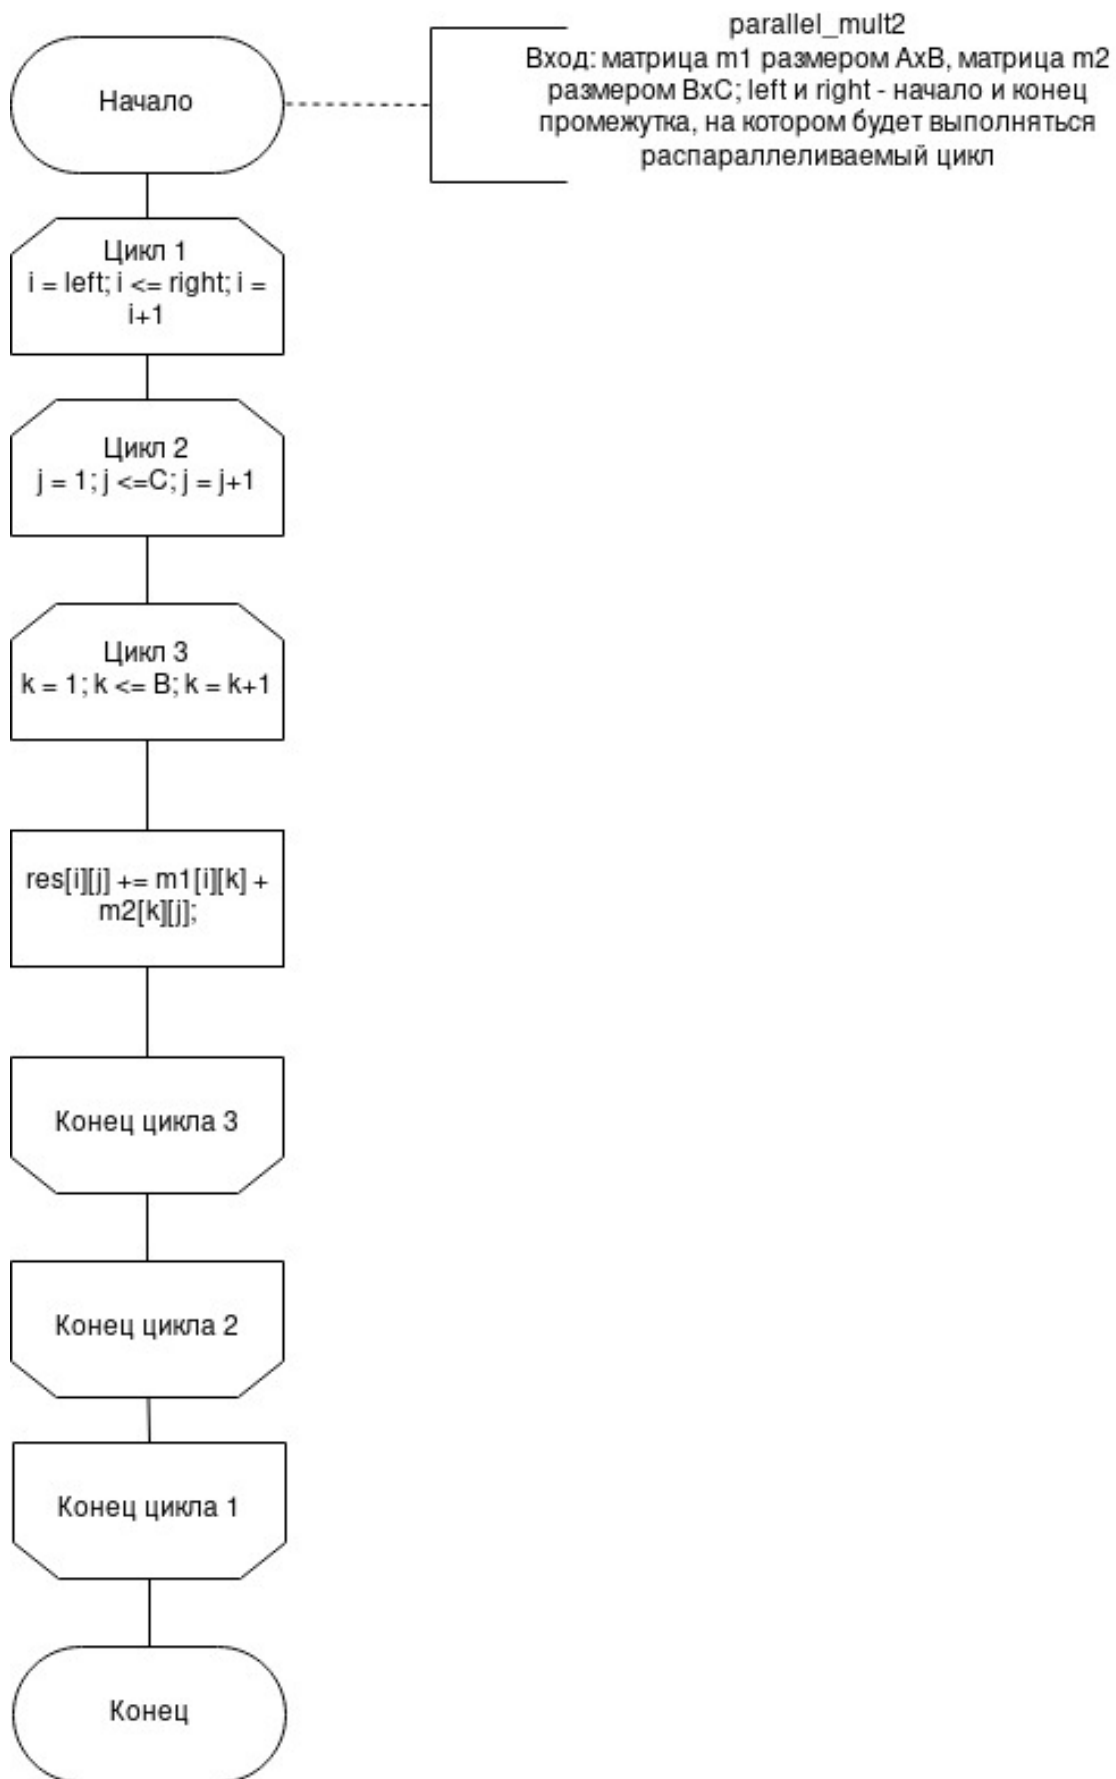


Рис. 2.2: Схема распараллеленного алгоритма умножения матриц, способ №1.

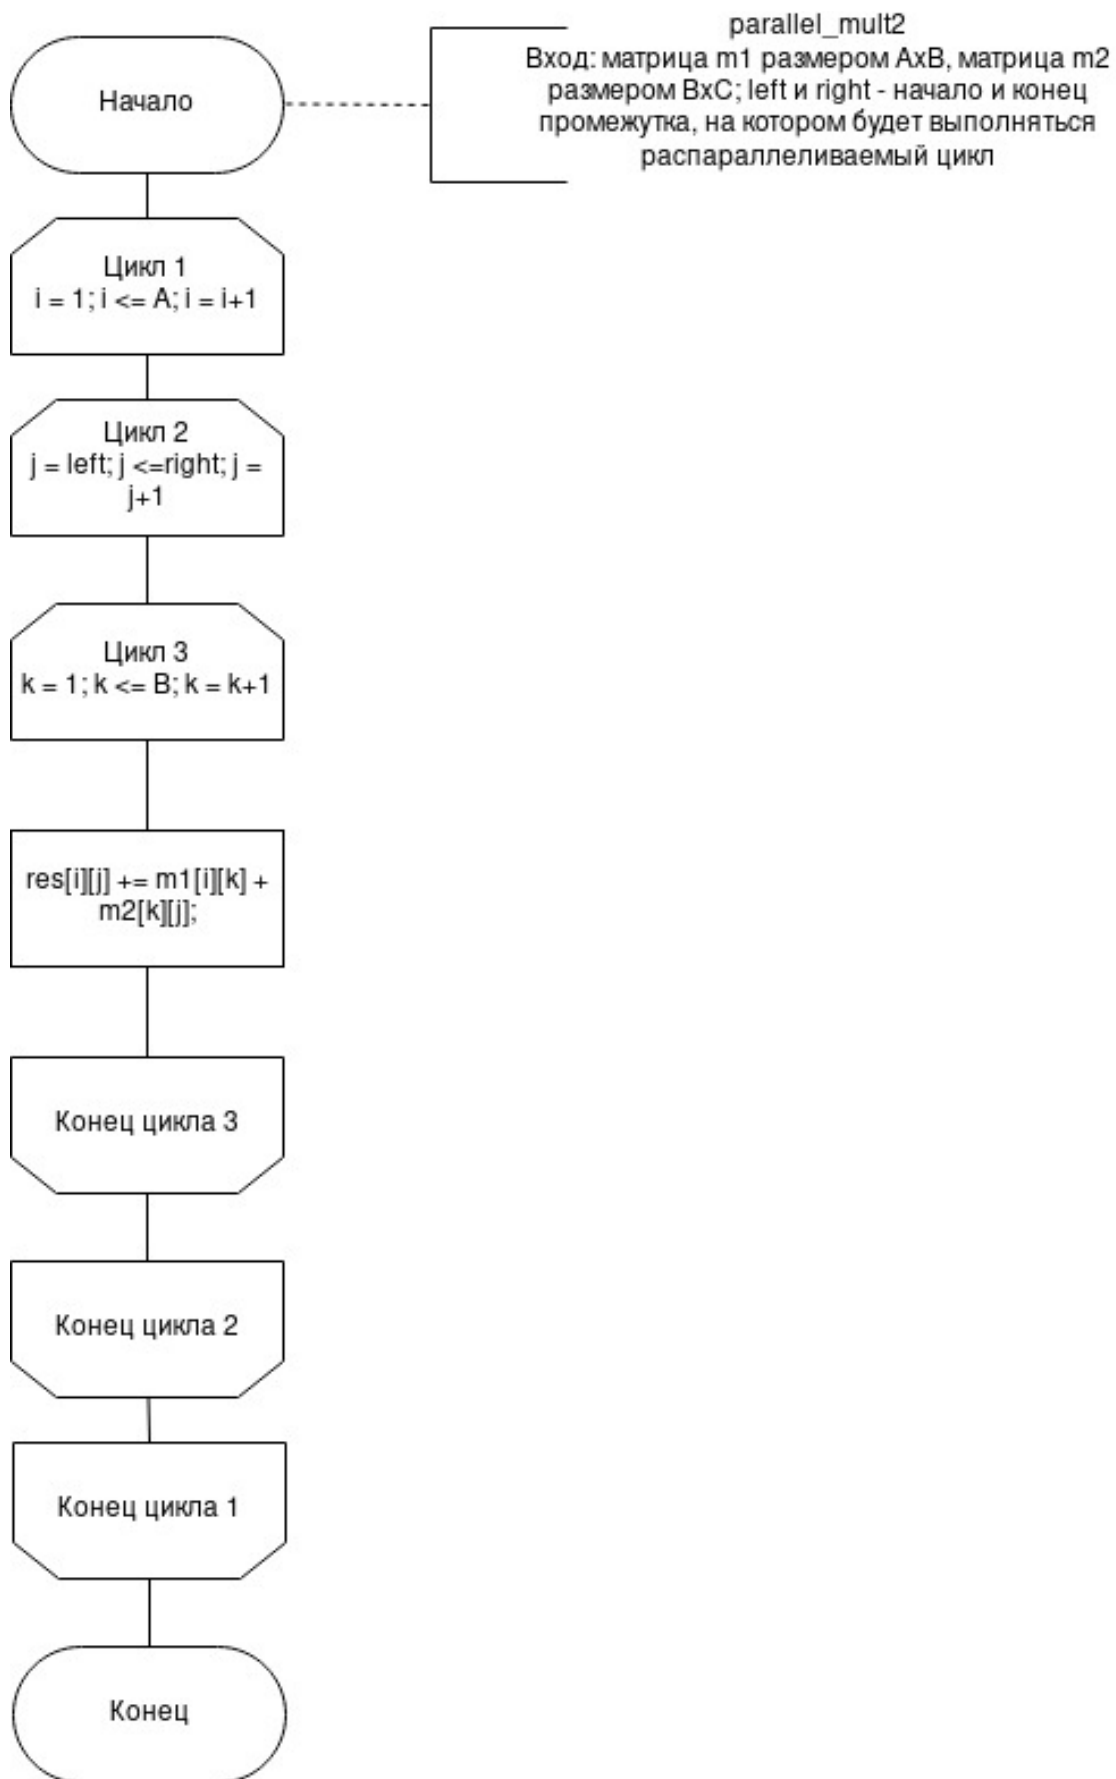


Рис. 2.3: Схема распараллеленного алгоритма умножения матриц, способ №2.

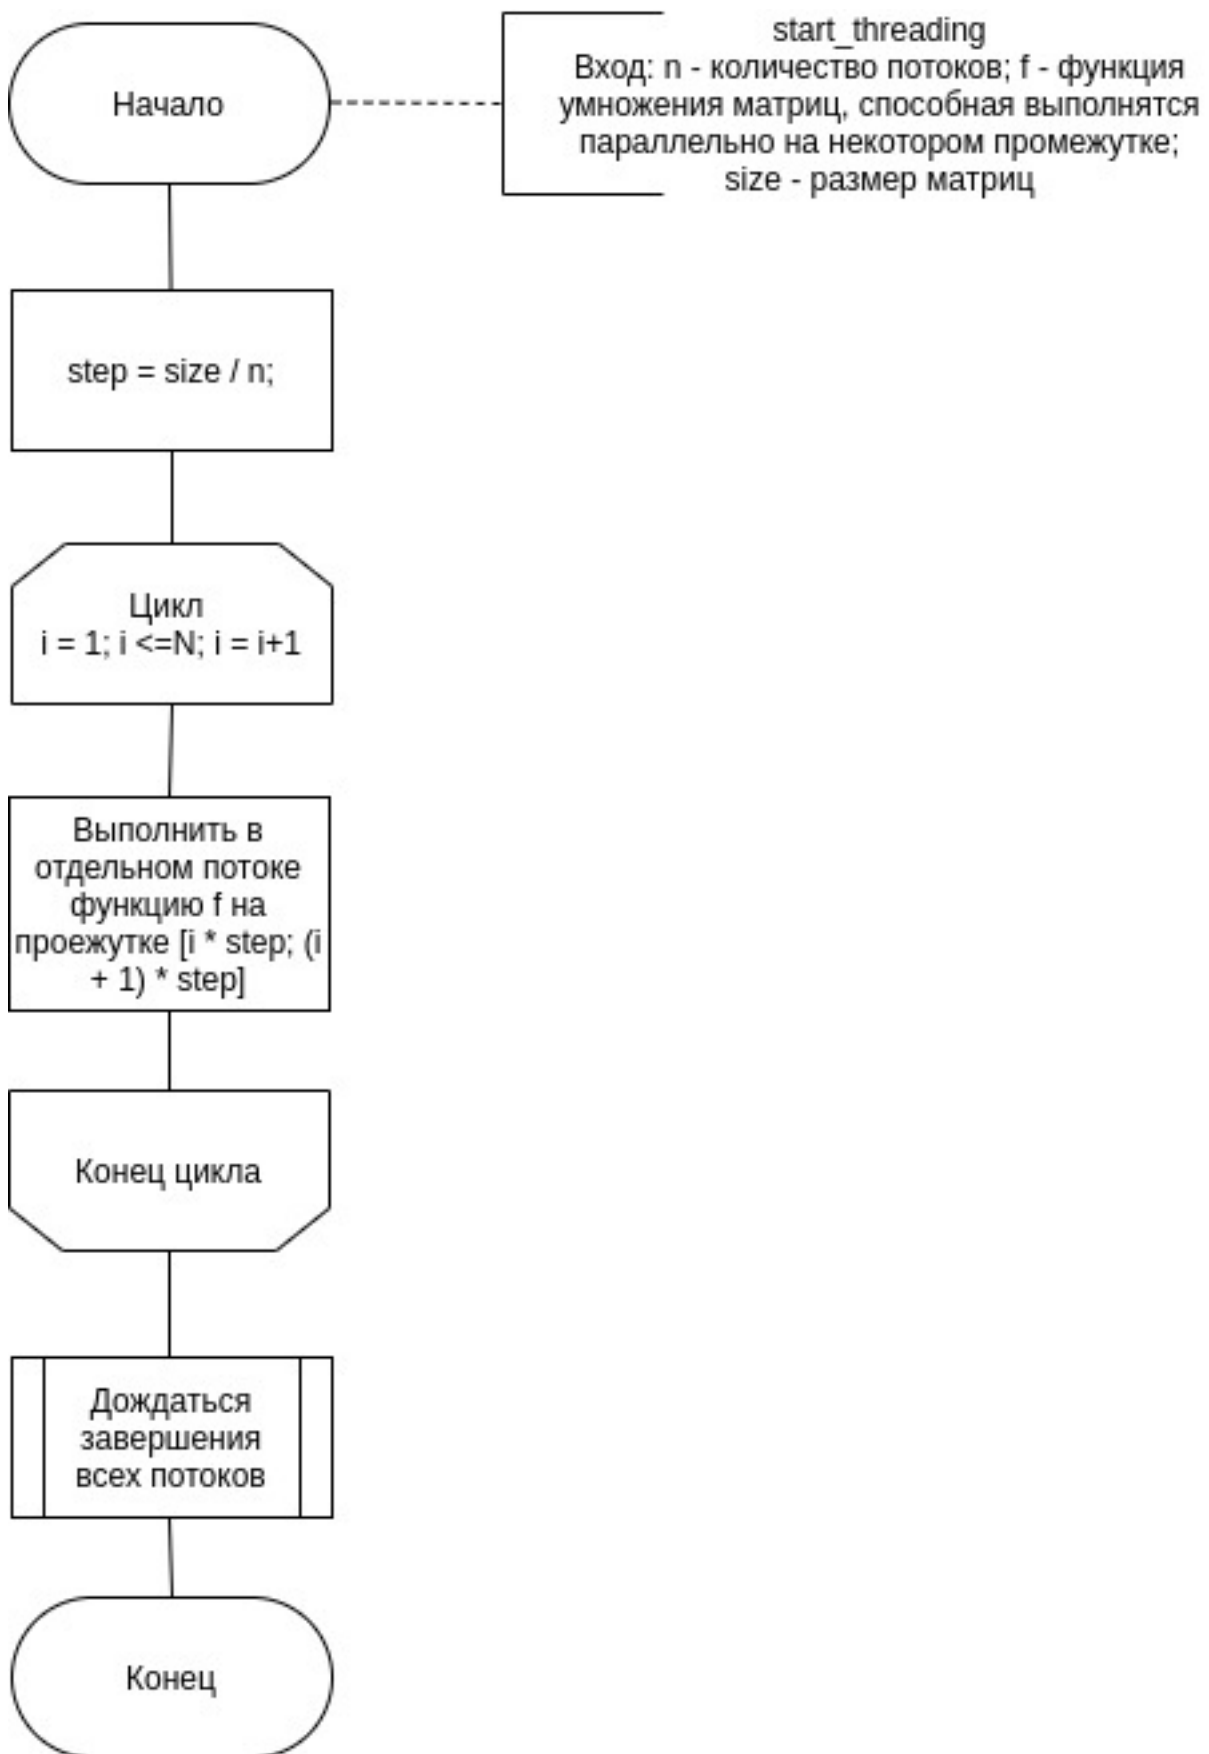


Рис. 2.4: Функция создания потоков и запуска параллельных реализация умножения матриц

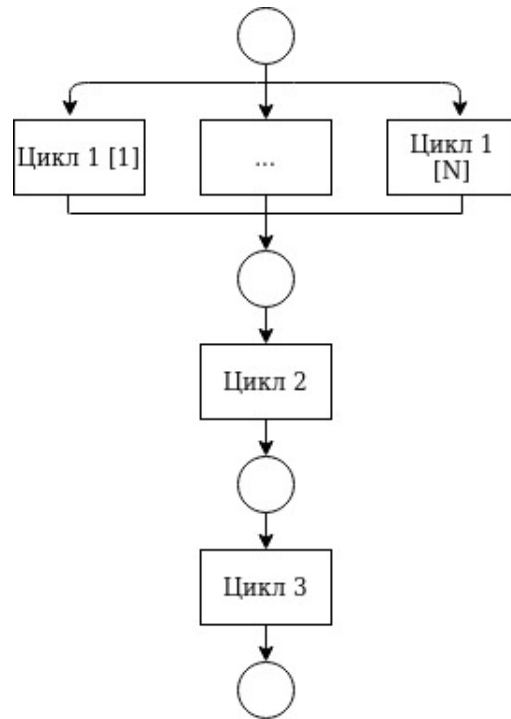


Рис. 2.5: Схема с параллельным выполнением первого цикла




Рис. 2.6: Схема с параллельным выполнением второго цикла

3 | Технологическая часть

В данном разделе приведены средства реализации и листинги кода.

3.1 Требование к ПО

К программе предъявляется ряд требований:

- на вход подаются размеры 2 матриц, а также их элементы;
- на выходе — матрица, которая является результатом умножения входных матриц.

3.2 Средства реализации

Для реализации ПО я выбрал язык программирования Си [3]. Данный выбор обусловлен высокой скоростью работы языка, а так же наличия инструментов для создания и эффективной работы с потоками.

3.3 Реализация алгоритмов

В листингах 3.1 - 3.3 приведена реализация рассмотренных ранее алгоритмов перемножения матриц. В листинге 3.4 приведена реализация функции создания и распределения потоков.

Листинг 3.1: Функция умножения матриц обычным способом

```
1 void base_multiplication(args_t *args) {  
2     for (int i = 0; i < N; i++) {  
3         for (int j = 0; j < K; j++) {  
4             args->res[i][j] = 0;  
5             for (int k = 0; k < M; k++) {  
6                 args->res[i][j] += args->m1[i][k] * args->m2[k][j];  
7             }  
8         }  
9     }  
10 }
```

Листинг 3.2: Функция умножения матриц параллельно. Способ №1

```
1 void *parallel_multiplication1(void *args) {
```

```

2 pthread_args_t *argsp = (args_t *)args;
3
4 int row_start = argsp->tid * (argsp->size / argsp->cnt_threads);
5 int row_end = (argsp->tid + 1) * (argsp->size / argsp->cnt_threads);
6
7 for (int i = row_start; i < row_end; i++) {
8     for (int j = 0; j < K; j++) {
9         argsp->mult_args->res[i][j] = 0;
10        for (int k = 0; k < M; k++) {
11            argsp->mult_args->res[i][j] += argsp->mult_args->m1[i][k] * argsp->
                mult_args->m2[k][j];
12        }
13    }
14 }
15
16 return NULL;
17 }

```

Листинг 3.3: Функция умножения матриц параллельно. Способ №2

```

1 void *parallel_multiplication2(void *args) {
2     pthread_args_t *argsp = (args_t *)args;
3
4     int col_start = argsp->tid * (argsp->size / argsp->cnt_threads);
5     int col_end = (argsp->tid + 1) * (argsp->size / argsp->cnt_threads);
6
7     for (int i = 0; i < N; i++) {
8         for (int j = col_start; j < col_end; j++) {
9             argsp->mult_args->res[i][j] = 0;
10            for (int k = 0; k < M; k++) {
11                argsp->mult_args->res[i][j] += argsp->mult_args->m1[i][k] * argsp->
                    mult_args->m2[k][j];
12            }
13        }
14    }
15
16    return NULL;
17 }

```

Листинг 3.4: Функция создания потоков

```

1 int start_threading(args_t *args, const int cnt_threads, const int type) {
2
3     pthread_t *threads = malloc(cnt_threads * sizeof(pthread_t));
4
5     if (!threads) {
6         return ALLOCATE_ERROR;
7     }
8
9
10    pthread_args_t *args_array = malloc(sizeof(pthread_args_t) * cnt_threads);

```

```

11
12  if (!args_array) {
13      free(threads);
14      return ALLOCATE_ERROR;
15  }
16
17  for (int i = 0; i < cnt_threads; i++) {
18      args_array[i].mult_args = args;
19      args_array[i].tid = i;
20      args_array[i].size = N;
21      args_array[i].cnt_threads = cnt_threads;
22
23      if (type == 1) {
24          pthread_create(&threads[i], NULL, parallel_multiplication1, &
25              args_array[i]);
26      } else {
27          pthread_create(&threads[i], NULL, parallel_multiplication2, &
28              args_array[i]);
29      }
30  }
31
32  for (int i = 0; i < cnt_threads; i++) {
33      pthread_join(threads[i], NULL);
34  }
35
36  free(args_array);
37  free(threads);
38
39  return OK;
40 }

```

3.4 Тестовые данные

В таблице 3.1 приведены тесты для функций, реализующих параллельное и обычное умножение матриц. Все тесты пройдены успешно.

3.5 Вывод

В данном разделе были разработаны исходные коды алгоритмов: обычный способ умножения матриц и два способа параллельного перемножения матриц.

Первая матрица	Вторая матрица	Ожидаемый результат
$\begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$	$\begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$	$\begin{pmatrix} 6 & 12 & 18 \\ 6 & 12 & 18 \\ 6 & 12 & 18 \end{pmatrix}$
$\begin{pmatrix} 1 & 2 & 2 \\ 1 & 2 & 2 \end{pmatrix}$	$\begin{pmatrix} 1 & 2 \\ 1 & 2 \\ 1 & 2 \end{pmatrix}$	$\begin{pmatrix} 5 & 10 \\ 5 & 10 \end{pmatrix}$
(2)	(2)	(4)
$\begin{pmatrix} 1 & -2 & 3 \\ 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$	$\begin{pmatrix} -1 & 2 & 3 \\ 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$	$\begin{pmatrix} 0 & 4 & 6 \\ 4 & 12 & 18 \\ 4 & 12 & 18 \end{pmatrix}$

Таблица 3.1: Тестирование функций

4 | Исследовательская часть

4.1 Технические характеристики

Ниже приведены технические характеристики устройства, на котором было проведено тестирование ПО:

- Операционная система: Debian [4] Linux [5] 11 «bullseye» 64-bit.
- Оперативная память: 12 GB.
- Процессор: Intel(R) Core(TM) i5-3550 CPU @ 3.30GHz [6].

4.2 Время выполнения алгоритмов

В таблице 4.1 приведено сравнение двух реализаций параллельного умножения матриц с разным количеством потоков при перемножении матриц размером 512. В таблице 4.2 приведено сравнение однопоточной реализации и многопоточных (с предварительным транспонированием и без) (на четырёх потоках).

Таблица 4.1: Таблица времени выполнения параллельных алгоритмов, при размерах перемножаемых матриц 512 (в тиках)

Количество потоков	П1	П2	ТП1	ТП2
1	2 808 685 166	2 811 309 156	2 505 297 765	2 543 312 143
2	1 418 843 814	1 420 505 354	1 390 440 763	1 327 401 234
4	754 354 852	749 388 813	735 231 324	731 238 763
8	761 861 636	753 869 394	744 110 083	743 132 552
16	756 535 197	755 651 844	751 231 324	745 231 233
32	777 543 386	766 654 800	759 231 323	751 231 973

4.3 Вывод

Наилучшее время параллельные алгоритмы показали на 4 потоках, что соответствует количеству логических ядер компьютера, на котором проводилось тестирование. На матрицах

Таблица 4.2: Таблица времени выполнения простого и параллельных алгоритмов (на 4 потоках) перемножения матриц (в тиках)

Размер матрицы	Обычный	П1	П2	ТП1	ТП2
64	11 569 478	4 423 500	4 399 005	3 774 315	3 880 419
128	59 224 135	16 626 572	17 706 987	14 993 123	14 709 974
256	354 152 337	98 670 198	93 640 191	91 623 197	94 227 134
512	2 719 059 760	755 595 299	751 307 775	710 340 123	705 231
1024	26 717 252 997	7 347 757 065	7 489 450 509	6 821 345 197	6 576 277 123

размером 512 на 512, параллельные алгоритмы улучшают время обычной (однопоточной) реализации перемножения матриц примерно в 3.5 раза. При количестве потоков, большее чем 4, параллельная реализация замедляет выполнение (в сравнении с 4 потоками). Кроме этого, я решил добавить в сравнение параллельное умножение с предварительным транспонированием: данный способ перемножения оказался самым эффективным (в среднем на 15% быстрее обычного параллельного умножения). Это можно объяснить кэшированием элементов.

Заключение

В рамках данной лабораторной работы была достигнута её цель: изучены параллельные вычисления. Также выполнены следующие задачи:

- было изучено понятие параллельных вычислений;
- были реализованы обычный и 2 параллельных реализаций алгоритма перемножения матриц;
- было произведено сравнение временных характеристик реализованных алгоритмов экспериментально.

Параллельные реализации алгоритмов выигрывают по скорости у обычной (однопоточной) реализации перемножения двух матриц. Наиболее эффективны данные алгоритмы при количестве потоков, совпадающем с количеством логических ядер компьютера. Так, например, на матрицах размером 512 на 512, удалось улучшить время выполнения алгоритма умножения матриц в 3.6 раза (в сравнении с однопоточной реализацией). Так же стоит отметить, что при дополнительном транспонировании второй матрицы, можно уменьшить время выполнения параллельных алгоритмов в среднем на 15%, что объясняется кэшированием элементов.

Литература

- [1] Mario Nemirovsky D. M. T. Multithreading Architecture // Morgan and Claypool Publishers. 2013.
- [2] Olukotun K. Chip Multiprocessor Architecture — Techniques to Improve Throughput and Latency // Morgan and Claypool Publishers. 2007. p. 154.
- [3] The C99 Standard. Режим доступа: <http://www.open-std.org/jtc1/sc22/wg14/www/docs/n1256.pdf>. Дата обращения: 16.09.2020.
- [4] Debian — универсальная операционная система [Электронный ресурс]. Режим доступа: <https://www.debian.org/>. Дата обращения: 20.09.2020.
- [5] Linux — Getting Started [Электронный ресурс]. Режим доступа: <https://linux.org>. Дата обращения: 20.09.2020.
- [6] Процессор Intel® Core™ i5-3550 [Электронный ресурс]. Режим доступа: <https://ark.intel.com/content/www/ru/ru/ark/products/65516/intel-core-i5-3550-processor-6m-cache-up-to-3-70-ghz.html>. Дата обращения: 20.09.2020.